

Master 2 Probabilité et Statistique des Nouvelles Données

Rapport de projet 1 : Estimation de densité

Auteur:
Amadou DIAGNE
Abdoulaye Gassama

Superviseur:
Binh-thuan Tran

Année académique 2026 - 2027

1 Définition du problème

L'objectif de ce rapport est de construire l'estimateur de la densité d'un échantillon de données par la méthode des noyaux. L'idée est de mesurer la concentration autour d'un point x en attribuant un certain poids selon la proximité des observations grâce à une fonction, appelée noyau, $K : \mathbb{R} \to \mathbb{R}$ vérifiant $\int K(u)\,du = 1$. L'estimateur à noyau est ainsi défini par :

$$\hat{f}_n(x) = \frac{1}{n}\sum_{i=1}^{n} \frac{1}{h} K\left(\frac{X_i - x}{h}\right)$$

où h représente le paramètre de lissage (ou fenêtre).

L'enjeu majeur de cette approche réside précisément dans le choix de ce paramètre h, déterminant pour le compromis entre le biais et la variance :

- Si h est trop petite, l'estimateur présente une forte variance et produit une courbe irrégulière (sous-lissage).
- Si h est trop grande, l'estimateur subit un biais important et masque les structures fines de la distribution (sur-lissage).

.
Enfin, face aux difficultés rencontrées lors du réglage manuel de ce paramètre, nous aborderons une approche automatisée par validation croisée afin de construire l'estimateur optimal.
Dans le cadre de ce rapport, l'analyse et l'application de l'estimateur seront effectuées en utilisant les noyaux rectangulaire et gaussien :

- $K(u) = \frac{1}{2} I(|u| \leq 1)$ (noyau rectangulaire)
- $K(u) = \frac{1}{\sqrt{2\pi}} \exp(-u^2/2)$ (noyau gaussien)

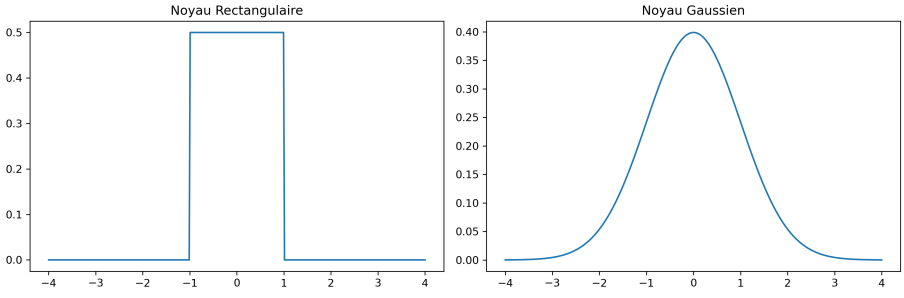


Figure 1: Illustration des noyaux rectangulaire et gaussien

2 Méthodologie et Interprétation

2.1 Données simulées

Dans cette partie, nous allons simuler l'échantillon à l'aide de la bibliothèque Python `NumPy`. L'échantillon $\mathbf{X}$ est de taille $n = 100$ et il est défini comme la concaténation $\mathbf{X} = (Y, Z)$ où :

$$\begin{cases} Y_i \sim \mathcal{N}(-1{,}5\,;\,2), & \text{pour } i = 1, \ldots, 50. \\ Z_i \sim \mathcal{U}([0,1]) & \text{pour } i = 1, \ldots, 50. \end{cases}$$

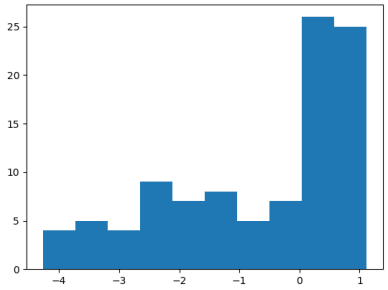


Figure 2: Histogramme des données X simulées

.

Tout naturellement, on observe sur l'intervalle $[-4, 0]$ la caractéristique forme en cloche de la densité gaussienne due au premier groupe de variables aléatoires. Le deuxième groupe impose, quant à lui, une densité uniforme plus élevée sur $[0, 1]$.

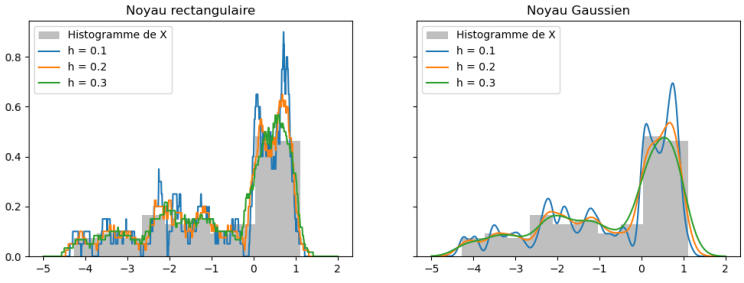


Figure 3: Impact de la fenêtre h sur l'estimation

.
L'analyse de la figure 3 permet d'identifier une fourchette de valeurs de h offrant un bon compromis entre bruit et sur-lissage. Pour déterminer la valeur optimale, nous utilisons la validation croisée.

2.2 Exploration manuelle de la fenêtre h

La principale difficulté pour une optimisation manuelle de h réside dans la recherche d'un point de départ. La règle de Silverman fournit une valeur de référence, définie par :

$$h_{\text{silverman}} = 0{,}9 \cdot \min\left(\hat{\sigma}, \frac{\text{IQR}}{1{,}34}\right) \cdot n^{-1/5}$$

où $\hat{\sigma}$ représente l'écart-type , IQR l'écart interquartile et n la taille de l'échantillon, elle est mathématiquement taillée pour des distributions unimodales ou proche de la loi normale. Appliquée à une distribution multimodale, elle génère un effet de sur-lissage. Par conséquent, cette valeur est utilisée comme limite supérieure à ne pas dépasser, ce qui nous amène à tester plusieurs valeurs de h inférieures à ce seuil pour restituer la structure réelle des données.

2.3 Sélection de h par validation croisée

Le principe de la validation croisée est le suivant : on cherche la valeur idéale

$$h_{id} = \underset{h>0}{\text{argmin}}\, \text{MISE}(h).$$

Néanmoins on ne peut pas la déterminer directement, car :

$$\text{MISE}(h) = \mathbb{E}[\int \hat{f}_h^2] - 2\mathbb{E}[\int \hat{f}_h f] + \int f^2$$

dépend de f qui est inconnu.

Le terme $\int f^2$ ne dépendant pas de h, il est constant,par conséquent, minimiser MISE(h) revient à minimiser

$$J(h) = \mathbb{E}[\int \hat{f}_h^2] - 2\mathbb{E}[\int \hat{f}_h f]$$

qui admet un minimum identique.

Par suite on minimise $\text{CV}(h) = \int \hat{f}_h^2 - \frac{2}{n}\sum_{i=1}^{n} \hat{f}_{h,-i}(X_i)$ qui est un estimateur sans biais de $J(h)$. La fenêtre optimale est alors:

$$h^* = \underset{h>0}{\text{argmin}}\, \text{CV}(h).$$

.
Une problématique restante dans la recherche de h^* est d'implémenter le calcul du terme $\int \hat{f}_h^2$ dans CV(h). Nous proposons d'approcher ce terme numériquement par la méthode des trapèzes.

Rappel sur la méthode des trapèzes

But : approcher $I = \int_a^b f(t)\,\mathrm{d}t$, où $f : [a,b] \to \mathbb{R}$.

On découpe l'intervalle $[a,b]$ en n sous-intervalles de même longueur, égale à $\frac{b-a}{n}$. Sur chacun de ces intervalles $[x_i, x_{i+1}]$, on approche l'intégrale $\int_{x_i}^{x_{i+1}} f(x)\,\mathrm{d}x$ par :

$$(x_{i+1} - x_i)\frac{f(x_i) + f(x_{i+1})}{2}.$$

On obtient ainsi l'approximation suivante de I :

$$I_n = \sum_{i=0}^{n-1} (x_{i+1} - x_i)\frac{f(x_i) + f(x_{i+1})}{2}.$$

Le deuxième terme $\frac{2}{n}\sum_{i=1}^{n} \hat{f}_{h,-i}(X_i)$ de $\mathrm{CV}(h)$ se calcule de manière matricielle à l'aide de `Numpy`.

Nous construisons ci-dessous l'estimateur optimal défini dans la section 1:

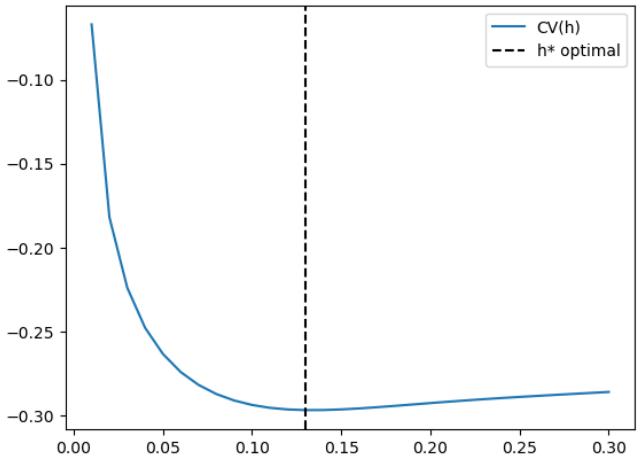


Figure 4: Illustration de la fonction validation croisée pour l'échantillon $\mathbf{X}$.

On obtient d'après la figure 4 que $h^* = 0.1298$.

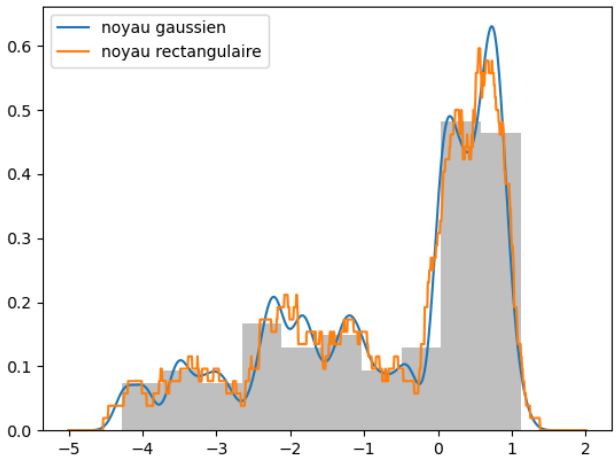


Figure 5: Estimateurs optimaux de la densité de $\mathbf{X}$ avec $h^* = 0.1298$ pour les noyaux rectangulaire et gaussien.

3 Application sur données réelles

Nous allons utiliser le jeu de données *mpg* de Seaborn qui est une version nettoyée du jeu de données *Auto MPG* de UCI machine learning. Par la même méthodologie utilisée précédemment nous construisons l'estimateur optimal de la variable `mpg_data`, qui mesure la consommation de carburant des véhicules, au sein du jeu données *mpg*.

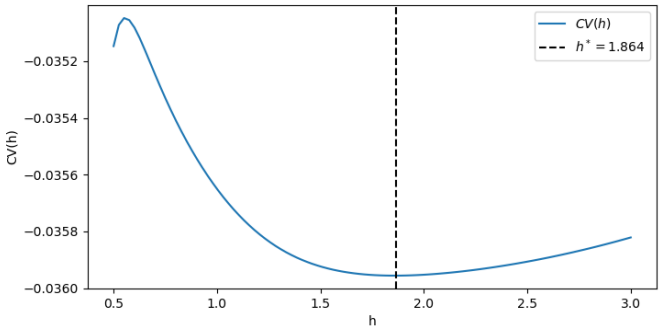


Figure 6: Illustration de la fonction CV(h)

On trouve par validation croisée d'après la figure 6 que $h^* = 1.864$.

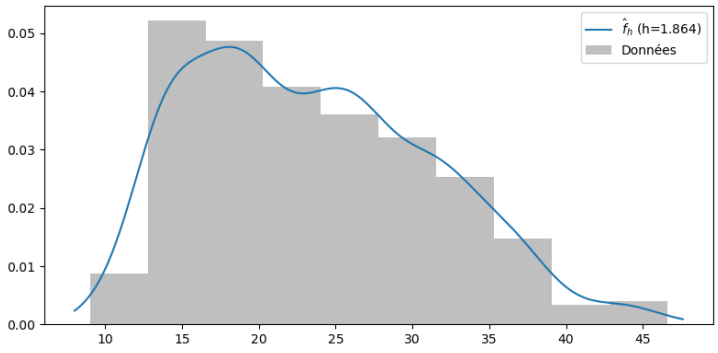


Figure 7: Estimateur de la densité de `mpg_data` par validation croisée

References

[1] Tsybakov, A. B. (2009). *Introduction to Nonparametric Estimation*. Springer Series in Statistics. Springer.

[2] Honkela, A. *Density estimation and cross validation*. Computational Statistics I, University of Helsinki. Disponible à l'adresse : `https://www.cs.helsinki.fi/u/ahonkela/teaching/compstats1/book/density-estimation-and-cross-validation.html`.